

18

Principal Components Regression

主元回归

输入特征主成分分析，输出数据投影到选定主元超平面



大理石中我看到了天使，我拿起刻刀不停雕刻，直到还它自由。

I saw the angel in the marble and carved until I set him free.

—— 米开朗琪罗 (Michelangelo) | 文艺复兴三杰之一 | 1475 ~ 1564



- ▶ `seaborn.relplot()` 绘制散点图和曲线图
- ▶ `seaborn.heatmap()` 绘制数据热图
- ▶ `seaborn.jointplot()` 绘制联合分布和边际分布
- ▶ `seaborn.kdeplot()` 绘制 KDE 核概率密度估计曲线
- ▶ `sklearn.decomposition.PCA()` 主成分分析函数
- ▶ `seaborn.lineplot()` 绘制线图
- ▶ `statsmodels.api.add_constant()` 线性回归增加一列常数 1
- ▶ `statsmodels.api.OLS()` 最小二乘法函数



本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

18.1 主元回归

本节讲解主元回归 (Principal Components Regression, PCR)。主元回归类似本章前文介绍的正交回归。多元正交回归中，自变量和因变量数据 $[X, y]$ 利用正交化，按照特征值从大小排列特征向量，用 $[v_1, v_2, \dots, v_D]$ 构造一个全新超平面， v_{D+1} 垂直于超平面关系求解出正交化回归系数。

而主元回归，因变量数据 y 完全不参与正交化，即仅仅 X 参与 PCA 分解，获得特征值由大到小排列 D 个主元 $V = (v_1, v_2, \dots, v_D)$ ；这 D 个主元方向 (v_1, v_2, \dots, v_D) 两两正交。选取其中 k ($k < D$) 个特征值较大主元 (v_1, v_2, \dots, v_k) ，构造超平面；最后一步，用最小二乘法将因变量 y 投影在超平面上。

图 1 提供一个例子， X 有三个维度数据， $X = [x_1, x_2, x_3]$ 。首先对 X 列向量 PCA 分解，获得正交化向量 $[v_1, v_2, v_3]$ 。然后，选取作为 v_1 和 v_2 主元，构造一个平面；用最小二乘法，将因变量 y 投影在平面上，获得回归方程。再次请大家注意，主元回归因变量 y 数据并不参与正交化；另外，主元回归选取前 P ($P < D$) 个特征值较大主元 $V_{D \times P} (v_1, v_2, \dots, v_P)$ ，构造一个超平面。

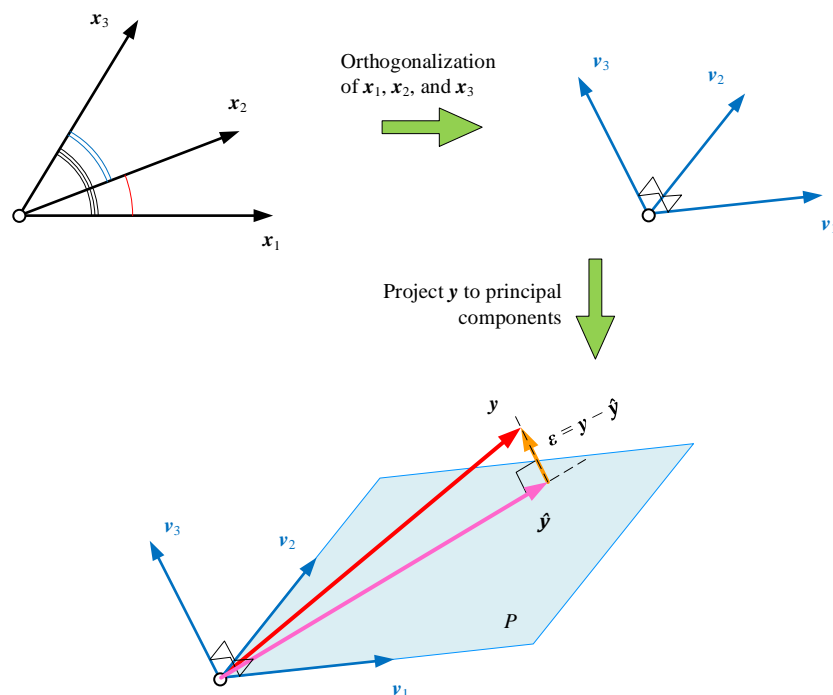


图 1. 主元回归原理

18.2 原始数据

下载如图 2 所示为归一化股价数据，将其转化为日收益率，作为数据 X 和 y ；其中 S&P 500 日收益率为数据 y ，其余股票日收益率作为数据 X 。图 3 所示为数据 X 和 y 的热图。




图 2. 股价走势，归一化数据




图 3. 数据 X 和 y 的热图

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

图 4 几个分图给出的是数据 X 和 y 的 KDE 分布。

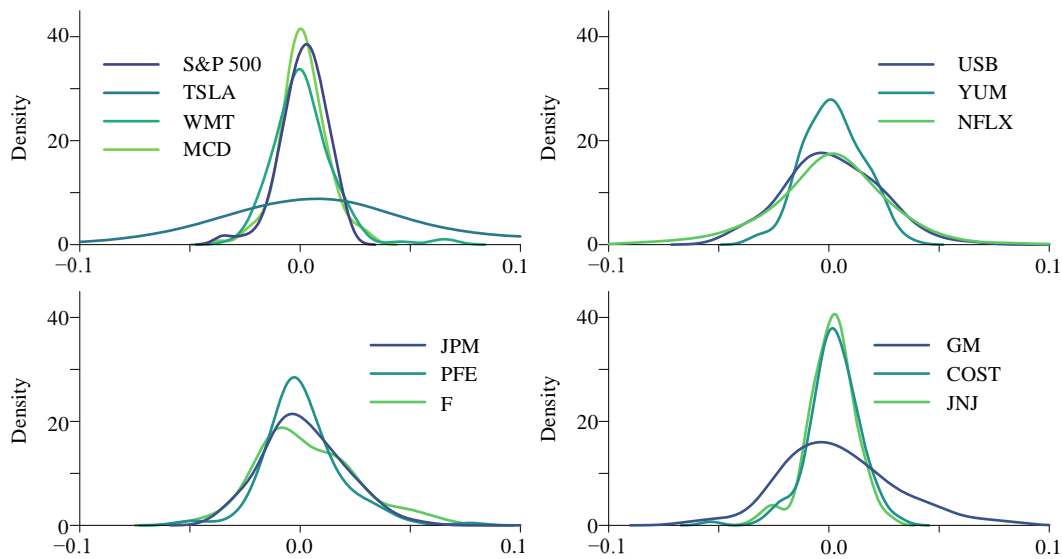


图 4. 数据 X 和 y 的 KDE 分布

18.3 主成分分析

对数据 X 进行主成分分析，可以获得如表 1 所示的前四个主成分 $V_{D \times p}$ 参数。可以利用热图和线图对 $V_{D \times p}$ 进行可视化，如图 5 所示。

表 1. 前四个主成分

	PC1	PC2	PC3	PC4
TSLA	-0.947	-0.004	0.256	0.121
WMT	-0.073	0.016	-0.193	0.066
MCD	-0.056	0.076	-0.111	0.115
USB	-0.021	0.503	0.122	-0.502
YUM	-0.044	0.188	-0.037	0.057
NFLX	-0.281	-0.133	-0.776	-0.448
JPM	-0.019	0.442	0.167	-0.425
PFE	-0.045	0.174	0.187	0.118
F	-0.004	0.457	-0.179	0.178
GM	0.007	0.491	-0.360	0.518
COST	-0.096	-0.027	-0.203	0.114
JNJ	-0.042	0.108	0.021	0.066




图 5. 前四个主成分可视化

图 5 所示 $V_{D \times p}$ 两两正交，具有如下性质：

$$V_{D \times p}^T V_{D \times p} = I_{p \times p}$$

(1)

图 6 所示为 (1) 计算热图。

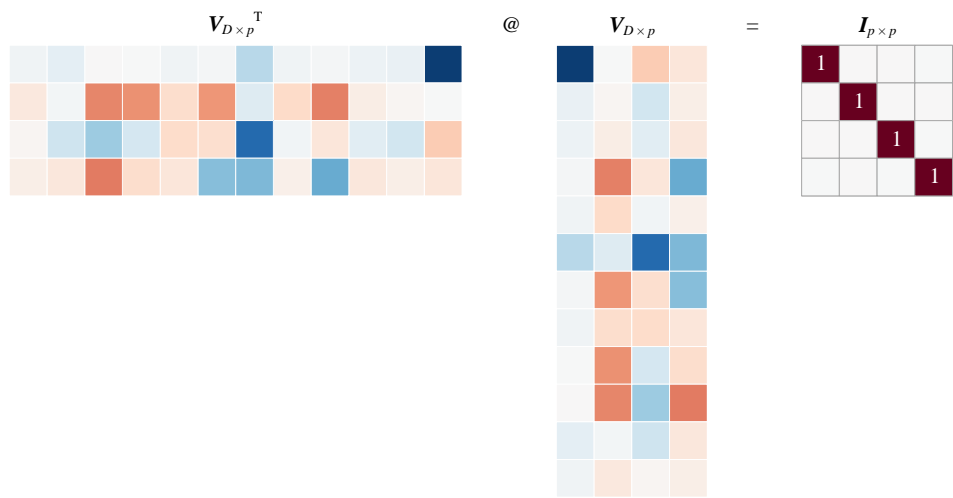


图 6. $V_{D \times p}$ 两两正交

18.4 数据投影

如图 7 所示，原始数据 X 在 p 维正交空间 $(v_1, v_2, ..., v_p)$ 投影得到数据 $Z_{n \times p}$ ：

$$Z_{n \times p} = X_{n \times D} V_{D \times p}$$
(2)

图 8 所示为 $Z_{n \times p}$ 数据热图。




图 7. PCA 分解部分数据关系




图 8. 前四个主成分数据

图 9 所示为 $Z_{n \times p}$ 每列主成分数据的分布情况。容易注意到，第一主成分数据解释最大方差。




图 9. 前四个主成分数据分布

图 10 所示为 $Z_{n \times p}$ 数协方差矩阵热图。




图 10. 前四个主元的协方差矩阵

前四个主成分对应的奇异值分别为：

$$s_1 = 0.5915, \quad s_2 = 0.4624, \quad s_3 = 0.2911, \quad s_4 = 0.2179 \quad (3)$$

所对应的特征值：

$$\begin{aligned} \lambda_1 &= \frac{s_1^2}{n-1} = \frac{0.5915^2}{126} = 0.0028 \\ \lambda_2 &= \frac{s_2^2}{n-1} = \frac{0.4624^2}{126} = 0.0017 \\ \lambda_3 &= \frac{s_3^2}{n-1} = \frac{0.2911^2}{126} = 0.00067 \\ \lambda_4 &= \frac{s_4^2}{n-1} = \frac{0.2179^2}{126} = 0.00038 \end{aligned} \quad (4)$$

这四个特征值对应图 10 热图对角线元素。如图 11 所示陡坡图，前四个主元解释了 84.87% 方差。

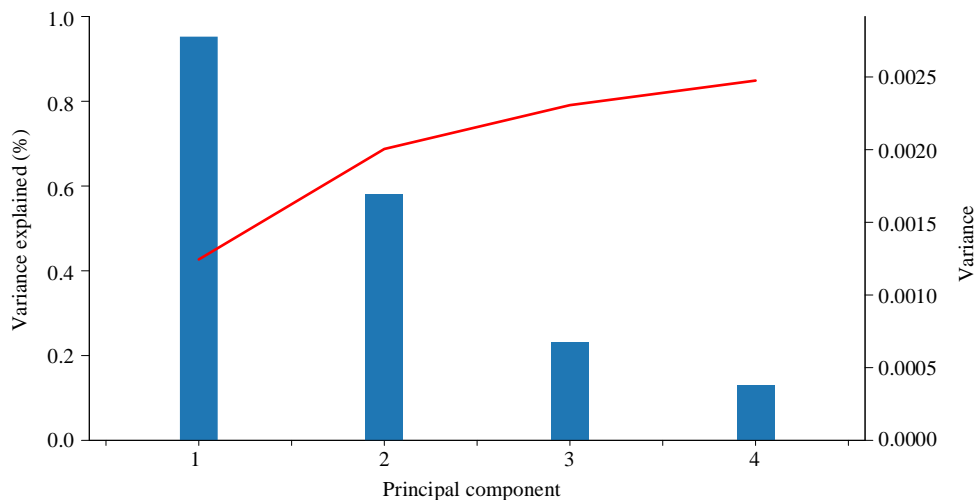


图 11. 陡坡图

转化矩阵 $Z_{n \times P}$ 仅包含 X 部分信息，两者信息之间差距通过下式计算获得，如图 12：

$$X_{n \times D} = Z_{n \times P} (V_{D \times P})^T + E_{n \times D} \quad (5)$$

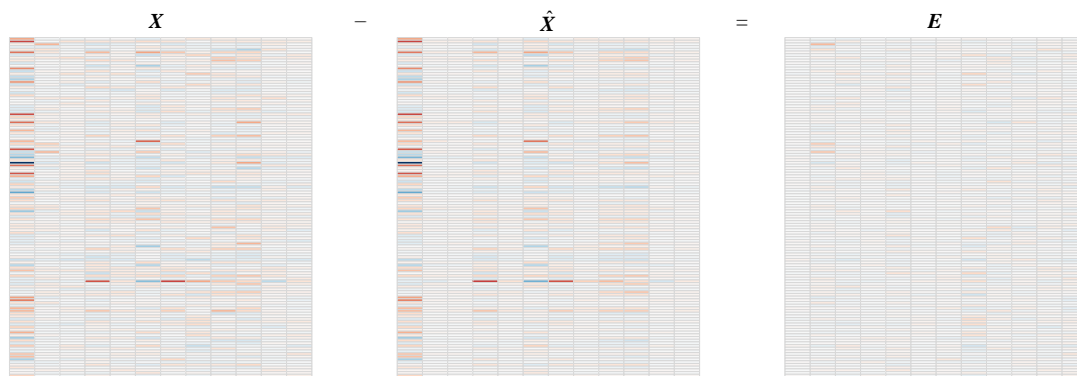


图 12. $Z_{n \times P}$ 还原数据和 X 信息差距

18.5 最小二乘法

主元回归最后一步，用最小二乘法把因变量 y 投影在数据 $Z_{n \times P}$ 构造空间中：

$$\hat{y} = b_{z,1}z_1 + b_{z,2}z_2 + \dots + b_{z,p}z_p \quad (6)$$

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

写成矩阵运算：

$$\hat{\mathbf{y}} = \begin{bmatrix} z_1 & z_2 & \cdots & z_p \end{bmatrix} \begin{bmatrix} b_{Z,1} \\ b_{Z,2} \\ \vdots \\ b_{Z,p} \end{bmatrix} = \mathbf{Z}_{n \times P} \mathbf{b}_Z \quad (7)$$

图 13 所示为上述运算过程。

$$\mathbf{y} = \mathbf{Z}_{n \times P} \times \mathbf{b}_Z + \boldsymbol{\varepsilon}$$

$n \times 1$ $n \times P$ $P \times 1$ $n \times 1$

图 13. 最小二乘法回归获得 $\mathbf{y} = \mathbf{Z}_{n \times P} \mathbf{b}_Z + \boldsymbol{\varepsilon}$

根据本书前文讲解内容最小二乘法解，获得 \mathbf{b}_Z ：

$$\begin{aligned} \mathbf{b}_Z &= (\mathbf{Z}_{n \times P}^T \mathbf{Z}_{n \times P})^{-1} \mathbf{Z}_{n \times P}^T \mathbf{y} \\ &= \left((\mathbf{X}_{n \times D} \mathbf{V}_{D \times P})^T (\mathbf{X}_{n \times D} \mathbf{V}_{D \times P}) \right)^{-1} (\mathbf{X}_{n \times D} \mathbf{V}_{D \times P})^T \mathbf{y} \end{aligned} \quad (8)$$

如图 13 所示， \mathbf{y} 、拟合数据 $\hat{\mathbf{y}}$ 和数据 $\mathbf{Z}_{n \times P}$ 关系如下：

$$\begin{cases} \mathbf{y} = \mathbf{Z}_{n \times P} \mathbf{b}_Z + \boldsymbol{\varepsilon} \\ \hat{\mathbf{y}} = \mathbf{Z}_{n \times P} \mathbf{b}_Z \\ \boldsymbol{\varepsilon} = \mathbf{y} - \hat{\mathbf{y}} \end{cases} \quad (9)$$

图 14 所示为最小二乘法线性回归结果。

系数向量 \mathbf{b}_Z 结果如下：

$$\mathbf{b}_Z = [-0.1039 \quad 0.1182 \quad -0.0941 \quad -0.0418]^T \quad (10)$$


OLS Regression Results						
=====						
Dep. Variable:	SP500	R-squared:	0.552			
Model:	OLS	Adj. R-squared:	0.537			
Method:	Least Squares	F-statistic:	37.60			
Date:	XXXXXXXXXX	Prob (F-statistic):	1.82e-20			
Time:	XXXXXXXXXX	Log-Likelihood:	450.53			
No. Observations:	127	AIC:	-891.1			
Df Residuals:	122	BIC:	-876.8			
Df Model:	4					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-0.0003	0.001	-0.520	0.604	-0.002	0.001
PC1	-0.1039	0.012	-8.647	0.000	-0.128	-0.080
PC2	0.1182	0.015	7.689	0.000	0.088	0.149
PC3	-0.0941	0.024	-3.854	0.000	-0.142	-0.046
PC4	-0.0418	0.033	-1.283	0.202	-0.106	0.023
=====						
Omnibus:	9.631	Durbin-Watson:	2.087			
Prob(Omnibus):	0.008	Jarque-Bera (JB) :	21.795			
Skew:	0.092	Prob(JB) :	1.85e-05			
Kurtosis:	5.021	Cond. No.	51.7			

图 14. 最小二乘法线性回归结果

下面将系数向量 \mathbf{b}_Z 利用 $(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_P)$ 转换为 \mathbf{b}_X ，具体过程图 15 所示：


$$\mathbf{b}_X = \mathbf{V}_{D \times P} \mathbf{b}_Z = \mathbf{V}_{D \times P} (\mathbf{Z}_{n \times P}^T \mathbf{Z}_{n \times P})^{-1} \mathbf{Z}_{n \times P}^T \mathbf{y} \quad (11)$$

图 15. \mathbf{b}_Z 和 \mathbf{b}_X 之间转换关系

系数 \mathbf{b}_X 可以通过下式计算得到：


$$\mathbf{b}_X = \mathbf{V}_{D \times P} \mathbf{b}_Z = \mathbf{V}_{D \times P} [-0.1039 \quad 0.1182 \quad -0.0941 \quad -0.0418]^T \quad (12)$$

图 16 所示为系数 \mathbf{b}_X 直方图。

图 16. 系数 b_x 直方图

这样获得 y 、拟合数据 \hat{y} 和数据 X 之间关系，如图 17 所示：

$$\begin{cases} y = Xb_x + \varepsilon \\ \hat{y} = Xb_x \\ \varepsilon = y - \hat{y} \end{cases} \quad (13)$$

图 17. y 和数据 X 之间回归方程

计算截距项系数 b_0 ：

$$b_0 = E(y) - [E(x_1) \ E(x_2) \ \cdots \ E(x_D)]b_x \quad (14)$$

计算截距项系数 b_0 ：

$$\begin{aligned} b_0 &= E(y) - [E(x_1) \ E(x_2) \ \cdots \ E(x_D)]b_x \\ &= -0.00034057 \end{aligned} \quad (15)$$

最后主元回归函数可以通过下式计算得到：

$$\begin{aligned}
 \hat{y} &= b_0 + b_1 x_1 + b_2 x_2 + \cdots + b_D x_D = b_0 + \begin{bmatrix} x_1 & x_2 & \cdots & x_D \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_D \end{bmatrix} = b_0 + \begin{bmatrix} x_1 & x_2 & \cdots & x_D \end{bmatrix} \mathbf{b}_x \\
 &= b_0 + \begin{bmatrix} z_1 & z_2 & z_3 & z_4 \end{bmatrix} \mathbf{V}_{D \times P} \mathbf{b}_Z \\
 &= b_0 + \begin{bmatrix} z_1 & z_2 & z_3 & z_4 \end{bmatrix} \begin{bmatrix} b_{z1} \\ b_{z2} \\ b_{z3} \\ b_{z4} \end{bmatrix}
 \end{aligned} \tag{16}$$

图 18 展示主元回归计算过程数据关系。




图 18. 主元回归数据关系

18.6 改变主元数量

对于主元回归，当改变参与最小二乘法线性回归的主元数量时，线性回归结果会有很大变化；本节将重点介绍主元数量对主元回归的影响。

图 19 所示为主元数量从 4 增加到 9 时，累计已释方差和百分比变化情况。图 20 和图 21 展示两个视角观察参与主元回归主元数量对于系数的影响。




图 19. 主元数量对累计已释方差和百分比




图 20. 参与主元回归主元数量对于系数的影响




图 21. 参与主元回归主元数量对于系数的影响，第二视角



Bk6_Ch18_01.py 完成主元回归运算图像。

18.7 偏最小二乘回归

本章最后介绍**偏最小二乘回归** (partial least squares regression, PLS)。类似主元回归，偏最小二乘回归也是一种降维回归方法。

不同于主元回归，偏最小二乘回归利用因变量数据 \mathbf{y} 和自变量数据 \mathbf{X} (形状为 $n \times q$) 之间相关性构造一个全新空间。 \mathbf{y} 和 \mathbf{X} 投影到新空间来确定一个线性回归模型。另外一个不同点，偏最小二乘回归采用**迭代算法** (iterative algorithm)。

偏最小二乘法处理多元因变量，为方便区分，一元因变量被定义为 \mathbf{y} (形状为 $n \times 1$)，多元因变量被定义为 \mathbf{Y} (形状为 $n \times p$)。偏最小二乘回归迭代方法很多，本节介绍较为经典一元因变量对多元自变量迭代算法。迭代算法主要由七步构成；其中，第二步到第七步为循环。

第一步

获得中心化自变量数据矩阵 $\mathbf{X}^{(0)}$ 和因变量数据向量 $\mathbf{y}^{(0)}$ ：

$$\begin{aligned} \mathbf{X}^{(0)} &= \left(\mathbf{I} - \frac{1}{n} \mathbf{U}^T \right) \mathbf{X} = \begin{bmatrix} \mathbf{x}_1^{(0)} & \mathbf{x}_2^{(0)} & \cdots & \mathbf{x}_q^{(0)} \end{bmatrix} \\ \mathbf{y}^{(0)} &= \mathbf{y} - \mathbf{E}(\mathbf{y}) = \left(\mathbf{I} - \frac{1}{n} \mathbf{U}^T \right) \mathbf{y} \end{aligned} \quad (17)$$

偏最小二乘回归是迭代运算，上标 (0) 代表迭代次数。




图 22. 计算权重系数列向量 \mathbf{w}_1

第二步

计算 $\mathbf{y}^{(0)}$ 和 $\mathbf{X}^{(0)}$ 列向量相关性，构建权重系数列向量 \mathbf{w}_1 ：

$$\mathbf{w}_1 = \begin{bmatrix} \text{cov}(\mathbf{x}_1^{(0)}, \mathbf{y}^{(0)}) \\ \text{cov}(\mathbf{x}_2^{(0)}, \mathbf{y}^{(0)}) \\ \vdots \\ \text{cov}(\mathbf{x}_q^{(0)}, \mathbf{y}^{(0)}) \end{bmatrix} = \frac{1}{n} \begin{bmatrix} (\mathbf{x}_1^{(0)})^T \mathbf{y}^{(0)} \\ (\mathbf{x}_2^{(0)})^T \mathbf{y}^{(0)} \\ \vdots \\ (\mathbf{x}_q^{(0)})^T \mathbf{y}^{(0)} \end{bmatrix} = (\mathbf{X}^{(0)})^T \mathbf{y}^{(0)} \quad (18)$$

其中，列向量 \mathbf{w}_1 行数为 q 行。

图 22 所示获得权重系数列向量计算过程；过程也可看做是一个投影运算，即将 $(\mathbf{X}^{(0)})^T$ 投影到 $\mathbf{y}^{(0)}$ 。

为方便计算，将列向量 \mathbf{w}_1 单位化：

$$\mathbf{w}_1 = \frac{\mathbf{w}_1}{\|\mathbf{w}_1\|} = \begin{bmatrix} w_{1,1} \\ w_{2,1} \\ \vdots \\ w_{q,1} \end{bmatrix} \quad (19)$$

列向量 \mathbf{w}_1 每个元素大小代表着 $\mathbf{y}^{(0)}$ 和 $\mathbf{X}^{(0)}$ 列向量相关性。

第三步，利用上一步获得权重系数列向量 \mathbf{w}_1 和 $\mathbf{X}^{(0)}$ 构造偏最小二乘回归主元向量， \mathbf{z}_1 ：

$$\mathbf{z}_1 = w_{1,1} \mathbf{x}_1 + w_{2,1} \mathbf{x}_2 + \cdots + w_{q,1} \mathbf{x}_q = \mathbf{X}^{(0)} \mathbf{w}_1 \quad (20)$$

图 23 所示为计算偏最小二程回归主元列向量 z_1 。这样理解，主元列向量 z_1 为 $X^{(0)}$ 列向量通过加权构造； $y^{(0)}$ 和 $X^{(0)}$ 某一列向量相关性越高，这一列获得权重越高，在主元列向量 z_1 成分越高。同样，过程等价于投影过程，即 $X^{(0)}$ 投影到 w_1 。




图 23. 计算偏最小二程回归主元列向量 z_1

将自变量数据矩阵 $X^{(0)}$ 和因变量数据向量 $y^{(0)}$ 投影到主元 z_1 方向上。

第四步

把自变量数据矩阵 $X^{(0)}$ 投影到主元列向量 z_1 上，获得系数向量 v_1 。先以 $X^{(0)}$ 第一列解释投影过程。




图 24. $X^{(0)}$ 第一列投影在主元列向量 z_1

如图 24 所示，将 $X^{(0)}$ 第一列投影到主元列向量 z_1 ，得到 $\hat{x}_1^{(0)}$ ：

$$\hat{x}_1^{(0)} = v_{1,1} z_1 \quad (21)$$

残差 ϵ 则垂直于主元列向量 z_1 ，计算获得系数 $v_{1,1}$ ：

$$\begin{aligned}\varepsilon \perp z_1 &\Rightarrow z_1^T \varepsilon = z_1^T (\mathbf{x}_1^{(0)} - \hat{\mathbf{x}}_1^{(0)}) = z_1^T (\mathbf{x}_1^{(0)} - v_{1,1} z_1) = 0 \\ \Rightarrow v_{1,1} &= \frac{z_1^T \mathbf{x}_1^{(0)}}{z_1^T z_1} = \frac{(\mathbf{x}_1^{(0)})^T z_1}{z_1^T z_1}\end{aligned}\quad (22)$$

上式说明偏最小二乘法回归核心仍是 OLS。同样，把 $\mathbf{X}^{(0)}$ 第二列投影在主元列向量 z_2 ，计算得到系数 $v_{2,1}$ ：

$$v_{2,1} = \frac{z_2^T \mathbf{x}_2^{(0)}}{z_2^T z_2} = \frac{(\mathbf{x}_2^{(0)})^T z_2}{z_2^T z_2} \quad (23)$$

类似，获得 $\mathbf{X}^{(0)}$ 每列投影在主元列向量 z_2 系数，这些系数一个列向量 \mathbf{v}_1 。下式计算列向量 \mathbf{v}_1 ：

$$\mathbf{v}_1 = \begin{bmatrix} v_{1,1} \\ v_{2,1} \\ \vdots \\ v_{q,1} \end{bmatrix} = \frac{(\mathbf{X}^{(0)})^T z_1}{z_1^T z_1} = \frac{(\mathbf{X}^{(0)})^T \mathbf{X}^{(0)} \mathbf{w}_1}{\mathbf{w}_1^T (\mathbf{X}^{(0)})^T \mathbf{X}^{(0)} \mathbf{w}_1} = \frac{\boldsymbol{\Sigma}^{(0)} \mathbf{w}_1}{\mathbf{w}_1^T \boldsymbol{\Sigma}^{(0)} \mathbf{w}_1} \quad (24)$$

第五步

根据最小二乘回归原理，利用列向量 \mathbf{v}_1 和 z_1 估算，并到拟合矩阵 $\hat{\mathbf{X}}^{(0)}$ ：

$$\hat{\mathbf{X}}^{(0)} = z_1 \mathbf{v}_1^T = \mathbf{X}^{(0)} \mathbf{w}_1 \mathbf{v}_1^T \quad (25)$$

原始数据矩阵 \mathbf{X} 和拟合数据矩阵 $\hat{\mathbf{X}}^{(0)}$ 之差便是残差矩阵 $\mathbf{E}^{(0)}$ ：

$$\mathbf{E}^{(0)} = \mathbf{X}^{(0)} - \hat{\mathbf{X}}^{(0)} = \mathbf{X}^{(0)} - \mathbf{X}^{(0)} \mathbf{w}_1 \mathbf{v}_1^T = \mathbf{X}^{(0)} (\mathbf{I} - \mathbf{w}_1 \mathbf{v}_1^T) \quad (26)$$

而残差矩阵 $\mathbf{E}^{(0)}$ 便是进入迭代过程第二步数据矩阵 $\mathbf{X}^{(1)}$ ：

$$\mathbf{X}^{(1)} = \mathbf{E}^{(0)} = \mathbf{X}^{(0)} - \hat{\mathbf{X}}^{(0)} = \mathbf{X}^{(0)} (\mathbf{I} - \mathbf{w}_1 \mathbf{v}_1^T) \quad (27)$$

数据矩阵 $\mathbf{X}^{(1)}$ 和原始数据 $\mathbf{X}^{(0)}$ 之间关系如图 25 所示。




图 25. 计算得到数据矩阵 $\mathbf{X}^{(1)}$

第六步

把因变量数据列向量 $\mathbf{y}^{(0)}$ 投影于主元列向量 \mathbf{z}_1 上，获得系数 b_1 。类似第四步，如图 26 所示，用最小二乘法计算获得系数 b_1 ：

$$\begin{aligned}\boldsymbol{\varepsilon} \perp \mathbf{z}_1 &\Rightarrow \mathbf{z}_1^T \boldsymbol{\varepsilon} = \mathbf{z}_1^T (\mathbf{y}^{(0)} - \hat{\mathbf{y}}^{(0)}) = \mathbf{z}_1^T (\mathbf{y}^{(0)} - b_1 \mathbf{z}_1) = 0 \\ \Rightarrow b_1 &= \frac{\mathbf{z}_1^T \mathbf{y}^{(0)}}{\mathbf{z}_1^T \mathbf{z}_1} = \frac{(\mathbf{y}^{(0)})^T \mathbf{z}_1}{\mathbf{z}_1^T \mathbf{z}_1}\end{aligned}\quad (28)$$




图 26. $\mathbf{y}^{(0)}$ 向量投影在主元列向量 \mathbf{z}_1

第七步


根据 OLS 原理，利用列向量 b_1 和 \mathbf{z}_1 估算因变量列向量 \mathbf{y} ，并到拟合 $\hat{\mathbf{y}}^{(0)}$ ：

$$\hat{\mathbf{y}}^{(0)} = b_1 \mathbf{z}_1 = \frac{\mathbf{z}_1^T \mathbf{y}^{(0)} \mathbf{z}_1}{\mathbf{z}_1^T \mathbf{z}_1} = \frac{(\mathbf{y}^{(0)})^T \mathbf{z}_1 \mathbf{z}_1}{\mathbf{z}_1^T \mathbf{z}_1} \quad (29)$$

原始因变量列向量 $\mathbf{y}^{(0)}$ 和拟合列向量 $\hat{\mathbf{y}}^{(0)}$ 之差便是残差向量 $\boldsymbol{\varepsilon}^{(0)}$ ：

$$\boldsymbol{\varepsilon}^{(0)} = \mathbf{y}^{(0)} - \hat{\mathbf{y}}^{(0)} = \mathbf{y}^{(0)} - \frac{\mathbf{z}_1^T \mathbf{y}^{(0)} \mathbf{z}_1}{\mathbf{z}_1^T \mathbf{z}_1} \quad (30)$$

而残差向量 $\boldsymbol{\varepsilon}^{(0)}$ 便是进入迭代循环第二步数据向量 $\mathbf{y}^{(1)}$ 。如图 27 所示， $\hat{\mathbf{y}}^{(0)}$ 解释部分 $\mathbf{y}^{(0)}$ 。

图 27. 估算 $y^{(0)}$

重复迭代

将数据矩阵 $X^{(1)}$ 和数据向量 $y^{(1)}$ 带入如上迭代运算第二步到第七步。

重复第二步得到权重系数列向量 w_2 ：

$$w_2 = \frac{(X^{(1)})^T y^{(1)}}{\|(X^{(1)})^T y^{(1)}\|} \quad (31)$$

重复第三步，利用权重系数列向量 w_2 和 $X^{(1)}$ 构造偏最小二乘回归第二主元向量， z_2 ：

$$z_2 = X^{(1)} w_2 \quad (32)$$

重复第四步，把自变量数据残差矩阵 $X^{(1)}$ 投影于第二主元列向量 z_2 上，获得系数向量 v_2 ：

$$v_2 = \begin{bmatrix} v_{1,2} \\ v_{2,2} \\ \vdots \\ v_{q,2} \end{bmatrix} = \frac{(X^{(1)})^T z_2}{z_2^T z_2} = \frac{(X^{(1)})^T X^{(1)} w_2}{w_2^T (X^{(1)})^T X^{(1)} w_2} = \frac{\Sigma^{(1)} w_2}{w_2^T \Sigma^{(1)} w_2} \quad (33)$$

重复第五步，用列向量 v_2 和 z_2 估算，并到拟合矩阵 $\hat{X}^{(1)}$ ：

$$\hat{X}^{(1)} = z_2 v_2^T = X^{(1)} w_2 v_2^T \quad (34)$$

$X^{(1)}$ 和拟合数据矩阵 $\hat{X}^{(1)}$ 之差便是残差矩阵 $E^{(1)}$ ， $E^{(1)}$ 便是再次进入迭代过程第二步数据矩阵 $X^{(2)}$ ：

$$X^{(2)} = E^{(1)} = X^{(1)} - \hat{X}^{(1)} = X^{(1)} (I - w_2 v_2^T) \quad (35)$$



图 28. 计算得到数据矩阵 $X^{(2)}$ 图 29. 前两个主元 z_1 和 z_2 还原数据矩阵 $X^{(0)}$

图 25 和图 28 相结合获得图 29，这即前两个主元 z_1 和 z_2 还原数据矩阵 $X^{(0)}$ 。随着主元数量不断增多，偏最小二乘回归更精确地还原原始数据 $X^{(0)}$ ；即说，对数据 $X^{(0)}$ 方差解释力度越强。

重复第六步，把因变量数据列向量 $y^{(1)}$ 投影在主元列向量 z_2 上，获得系数 b_2 ：

$$b_2 = \frac{z_2^T y^{(1)}}{z_2^T z_2} = \frac{(y^{(1)})^T z_2}{z_2^T z_2} \quad (36)$$

重复第七步，利用 b_2 和 z_2 得到拟合列向量 $\hat{y}^{(1)}$ ：

$$\hat{y}^{(1)} = b_2 z_2 \quad (37)$$

列向量 $y^{(1)}$ 和拟合数据列向量 $\hat{y}^{(1)}$ 之差便是残差向量 $\epsilon^{(1)}$ ：

$$\epsilon^{(1)} = y^{(1)} - \hat{y}^{(1)} = y^{(1)} - b_2 z_2 \quad (38)$$

而残差向量 $\epsilon^{(1)}$ 也是进入下一次迭代过程第二步数据向量 $y^{(2)}$ 。




图 30. 估算 $y^{(1)}$

图 31 结合图 27 和图 30，这幅图中前两个主元 z_1 和 z_2 还原部分数据列向量 $y^{(0)}$ 。同理，随着主元数量不断增多，偏最小二乘回归更精确地还原原始因变量列向量 $y^{(0)}$ ；即，对 $y^{(0)}$ 方差解释力度越强。截止目前，迭代循环已经完成两次。




图 31. 前两个主元 z_1 和 z_2 还原部分数据列向量 $y^{(0)}$

Scikit-learn 中 PLS 回归的函数为 `sklearn.cross_decomposition.PLSRegression()`。



下例展示如何使用偏最小二乘回归。这个例子还比较了本书最后一章要介绍的典型相关分析。请大家自行阅读学习：

https://scikit-learn.org/stable/auto_examples/cross_decomposition/plot_compare_cross_decomposition.html